

Prediksi Tingkat Atrisi Karyawan Menggunakan *Machine Learning*

RESA RIANI¹, RONI ANDARSYAH²

Universitas Logistik dan Bisnis Internasional, Indonesia
Email : riantiresa224@gmail.com

Received 30 November 201x | *Revised* 30 Desember 201x | *Accepted* 30 Januari 201x

ABSTRAK

Pengurangan karyawan merupakan masalah serius bagi keunggulan kompetitif organisasi dan mahal dalam hal biaya, termasuk siklus hidup sumber daya manusia, hilangnya pengetahuan, semangat kerja, dan budaya organisasi. Atrisi karyawan terjadi karena berbagai faktor tidak dapat dihindarkan, menyebabkan kerugian besar. Untuk mengatasi hal ini, penting bagi perusahaan untuk memahami faktor-faktor yang mempengaruhi atrisi karyawan. Penelitian ini menggunakan metode pemilihan fitur untuk mengidentifikasi faktor-faktor tersebut dan menyederhanakan pelatihan data menggunakan dataset HR Analytics dari Data World. Algoritma supervised learning seperti Logistic Regression dan Support Vector Machine (SVM) digunakan untuk memodelkan dan memprediksi atrisi karyawan, menggunakan metode CRISP-DM. Hasil penelitian menunjukkan bahwa Logistic Regression mencapai akurasi 86,39% sementara SVM mencapai akurasi 84,81%. Temuan ini menunjukkan bahwa machine learning dapat membantu perusahaan mengelola dan mengurangi atrisi karyawan, meningkatkan strategi retensi dan kepuasan kerja, serta mendorong pertumbuhan ekonomi perusahaan.

Kata kunci: Atrisi Karyawan, Machine Learning, Logistic Regression, Support Vector Machine, HR Analytics, CRISP-DM, Retensi Karyawan, Kepuasan Kerja, Prediksi Atrisi

ABSTRACT

Employee attrition is a serious problem for an organization's competitive advantage and is costly in terms of costs, including the life cycle of human resources, loss of knowledge, morale, and organizational culture. Employee attrition occurs due to various unavoidable factors, causing huge losses. To overcome this, it is important for companies to understand the factors that influence employee attrition. This research uses feature selection methods to identify such factors and simplify data training using Data World's HR Analytics dataset. Supervised learning algorithms such as Logistic Regression and Support Vector Machine (SVM) were used to model and predict employee attrition, following the CRISP-DM method. The results showed that Logistic Regression achieved 86.39% accuracy while SVM achieved 84.81% accuracy. The findings suggest that machine learning can help companies manage and reduce employee attrition, improve retention strategies and job satisfaction, and drive economic growth.

Keywords: Employee Attrition, Machine Learning, Logistic Regression, Support Vector Machine, HR Analytics, CRISP-DM, Employee Retention, Job Satisfaction, Attrition Prediction

1. PENDAHULUAN

Dalam upaya mencapai kesuksesan, perusahaan perlu memiliki strategi jangka panjang yang mempertimbangkan kekuatan dan kelemahan internal serta ancaman eksternal. Salah satu masalah yang dihadapi adalah pengelolaan tenaga kerja yang kompleks, mulai dari perekrutan hingga pengembangan. Sumber daya manusia sangat penting dalam organisasi dan diperlukan untuk mencapai tujuan perusahaan **(Wardhani & Lhaksmana, 2022)**. Oleh karena itu, manajemen yang baik diperlukan dalam seleksi karyawan agar semua sumber daya manusia memenuhi kualifikasi dan mendukung kemajuan perusahaan.

Dalam suatu perusahaan, atrisi karyawan menjadi isu penting yang perlu ditangani. Proses seleksi ini penting karena investasi waktu dan uang yang dikeluarkan serta potensi kerugian jika sumber daya manusia ini meninggalkan organisasi **(Suindari & Juniariyani, 2020)**. Atrisi karyawan merujuk pada jumlah karyawan yang meninggalkan perusahaan dalam periode waktu tertentu. Tingkat atrisi yang tinggi dapat berdampak negatif pada produktivitas, stabilitas, dan biaya perusahaan. Faktor-faktor seperti karakteristik pribadi, faktor sistem perusahaan, dan lingkungan kerja dapat mempengaruhi keputusan karyawan untuk meninggalkan perusahaan **(Umami, n.d.)**. Oleh karena itu, penting bagi divisi SDM untuk memahami faktor-faktor yang berpengaruh dalam atrisi karyawan.

Salah satu pendekatan yang dapat digunakan adalah membangun model pembelajaran mesin untuk memprediksi tingkat atrisi karyawan dengan menggunakan proses data mining. Data Mining adalah proses analisis data untuk menemukan hubungan yang jelas dan menghasilkan kesimpulan baru yang berguna bagi pemilik data. Terdapat beberapa bagian dalam Data Mining seperti asosiasi, prediksi, klasifikasi, pengelompokan, dan regresi. Dalam konteks ini, penggabungan pendekatan data mining dapat membantu divisi SDM mengambil langkah yang lebih proaktif dalam mengurangi pengurangan karyawan **(And & Expert, 2022)**.

Dengan demikian, perusahaan dapat menghindari biaya dan waktu yang diperlukan untuk merekrut dan melatih karyawan baru. Selain itu, dengan memahami faktor-faktor yang berkontribusi pada atrisi karyawan, perusahaan dapat menerapkan strategi yang lebih efektif untuk meningkatkan kepuasan kerja, memperbaiki sistem perusahaan, dan menciptakan lingkungan kerja yang lebih baik **(Setia Arindi et al., 2023)**. Hal ini akan berdampak positif pada kinerja perusahaan secara keseluruhan dan membantu mencapai tujuan jangka panjang yang telah ditetapkan.

Dalam penelitian ini, digunakan data HR Analytics dari platform Data World yang mencakup berbagai fitur seperti usia, peran karyawan, tarif harian, kepuasan kerja, tahun di perusahaan, dan lain-lain. Penelitian ini bertujuan untuk menganalisis faktor-faktor penyebab karyawan meninggalkan perusahaan. Penelitian ini, menggunakan pendekatan machine learning dengan metode supervised learning digunakan untuk mengklasifikasikan data. Supervised learning merupakan metode di mana kita dapat memberikan label khusus pada setiap pengamatan. Sebagai contoh, dalam sebuah perusahaan e-commerce berusaha meningkatkan layanan pelanggan dengan menerapkan model machine learning untuk memprediksi tingkat kepuasan pelanggan. Data transaksi pelanggan, seperti waktu pengiriman, jumlah produk, tingkat diskon, dan umpan balik, digunakan dalam studi ini. Melalui pre-processing data, algoritma Support Vector Machines (SVMs) dipilih untuk melatih model yang dapat memahami pola hubungan antara fitur-fitur tersebut dan tingkat kepuasan pelanggan. Sejumlah algoritma yang termasuk dalam kelompok supervised learning melibatkan teknik-teknik seperti Regresi Linear, Regresi Logistik, Analisis Diskriminan Linear, k-Nearest Neighbors, Support Vector Machines (SVMs), Random Forest, Decision Tree, dan Naive Bayes **(Santoso et al., 2021)**.

Teknik Regresi Linear digunakan untuk menemukan hubungan linier antara variabel independen dan dependen, sementara Regresi Logistik lebih cocok untuk memodelkan probabilitas kejadian biner. Analisis Diskriminan Linear berfokus pada pemisahan kelas, k-Nearest Neighbors memanfaatkan kedekatan data, SVMs menciptakan batas keputusan linier atau non-linier, Random Forest menggabungkan keputusan dari banyak pohon keputusan, Decision Tree memetakan keputusan berdasarkan serangkaian aturan, dan Naive Bayes menggunakan teorema Bayes untuk menghitung probabilitas kelas. Gabungan algoritma ini memberikan fleksibilitas dalam menangani berbagai jenis data dan permasalahan prediksi **(Raza et al., 2022)**.


Penelitian memprediksi atrisi karyawan dengan metode supervised learning digunakan dengan menggunakan dua algoritma, yaitu Logistic Regression dan Support Vector Machine (SVM), sebagai perbandingan untuk melakukan prediksi atrisi karyawan dalam data HR Analytics.

Logistic Regression adalah sebuah metode statistik yang digunakan untuk memodelkan hubungan antara variabel dependen (dalam hal ini, tingkat atrisi karyawan) dengan satu atau lebih variabel independen (faktor-faktor yang mempengaruhi atrisi). Tujuan dari Logistic Regression adalah untuk memprediksi probabilitas kejadian suatu peristiwa berdasarkan nilai-nilai variabel independent **(Setiawan et al., 2020)**. Model Logistic Regression menghasilkan output dalam bentuk probabilitas yang dapat diinterpretasikan sebagai kemungkinan terjadinya suatu peristiwa.

Sedangkan Support Vector Machine (SVM) adalah sebuah algoritma pembelajaran mesin yang digunakan untuk klasifikasi dan regresi. Dalam konteks ini, SVM digunakan untuk memprediksi tingkat atrisi karyawan berdasarkan data HR Analytics. SVM mencari pemisah optimal antara dua kelas dengan mencari hyperplane terbaik yang memaksimalkan jarak antara kelas-kelas tersebut **(Octaviani et al., 2014)**. SVM juga dapat mengatasi masalah non-linear dengan menggunakan kernel untuk mentransformasi data ke dimensi yang lebih tinggi. Dengan menggunakan kedua algoritma ini, penelitian ini bertujuan untuk membandingkan kinerja Logistic Regression dan SVM dalam memprediksi atrisi karyawan dalam dataset HR Analytics **(Biswas et al., 2023)**.

2. METODE PENELITIAN

CRISP-DM (Cross-Industry Standard Process for Data Mining) adalah suatu pendekatan metodologi yang umumnya diterapkan dalam proses data mining. Metodologi ini mengikuti serangkaian langkah-langkah terstruktur yang dimulai dari pemahaman bisnis hingga evaluasi hasil **(Purnama et al., n.d.)**. Pertama, tahap Pemahaman Bisnis melibatkan identifikasi tujuan bisnis, kebutuhan data, dan pemahaman konteks masalah. Selanjutnya, Eksplorasi Data melibatkan pemeriksaan dan pemahaman mendalam terhadap data yang ada. Tahap Persiapan Data melibatkan pembersihan, transformasi, dan penggabungan data untuk memastikan kualitas dan keterpakaianya. Setelah itu, tahap Pemodelan terlibat dalam pemilihan, pelatihan, dan evaluasi model data mining yang sesuai. Validasi berlanjut melalui Evaluasi, di mana model diuji dan dievaluasi kinerjanya. Terakhir, tahap Penerapan mengimplementasikan solusi data mining dalam lingkungan bisnis. Dengan pendekatan yang terstruktur ini, CRISP-DM memberikan panduan yang jelas untuk mengoptimalkan proses data mining dan meningkatkan pemahaman serta penerapan hasilnya dalam konteks bisnis yang relevan **(Fadillah, 2015)**.



Gambar 1. CRISP-DM

Pada ilustrasi dalam Gambar diatas, tahapan proses CRISP DM dijelaskan sebagai berikut.

2.1 Business Understanding

Langkah awal dalam siklus CRISP-DM adalah Pemahaman Bisnis, yang bertujuan untuk memahami kebutuhan dan tujuan bisnis serta menerjemahkan pemahaman tentang bisnis menjadi definisi masalah dalam konteks data(Wurijanto et al., 2022). Tahap ini mencakup pemahaman mendalam tentang tujuan bisnis, hambatan yang dihadapi, dan kebutuhan informasi yang harus dipenuhi. Dalam penelitian ini, data diperlukan dari berbagai sumber terkait atrisi karyawan, dan dilakukan analisis untuk mengidentifikasi faktor-faktor yang paling berpengaruh terhadap atrisi karyawan. Hal ini bertujuan untuk mengembangkan model prediksi yang dapat memberikan kontribusi signifikan terhadap pemahaman dan penanganan masalah atrisi karyawan(Alsheref et al., 2022).

2.2 Data Understanding

Tahap kedua dalam model CRISP-DM adalah Eksplorasi Data, di mana dilakukan pengumpulan data, deskripsi data, dan evaluasi kualitas data. Proses ini melibatkan pencarian, analisis, dan penilaian data yang akan digunakan dalam penelitian. Data yang dikumpulkan berasal dari berbagai sumber, termasuk studi sebelumnya dan wawancara dengan para ahli terkait. Informasi diperoleh dari literatur yang berasal dari beragam media, seperti buku, artikel, atau jurnal, dan karya ilmiah (Qutub et al., 2021).

2.3 Data Preparation

Langkah ketiga dalam siklus CRISP-DM adalah Persiapan Data, yang melibatkan proses pembentukan dataset dari data yang telah dikumpulkan. Tahap ini memastikan dataset yang digunakan untuk melatih dan menguji model prediksi memiliki integritas yang baik, variabel yang relevan, dan keseimbangan yang sesuai untuk membangun model yang dapat memberikan hasil prediksi atrisi karyawan yang akurat(Stamolampros et al., 2019).

2.4 Modelling

Langkah Pemodelan melibatkan implementasi Machine Learning untuk menentukan teknik data mining, dan algoritma data mining yang sesuai dengan tujuan analisis. Dalam konteks penelitian ini, model regresi logistik dan support vector machine digunakan sebagai metode untuk menganalisis data dan merumuskan prediksi tingkat attrisi karyawan.

2.5 Evaluation

Pada tahap ini, model yang telah dirancang akan diujicoba dan dievaluasi guna mengukur tingkat keakuratan. Tahap evaluasi ini penting untuk menilai sejauh mana model yang telah dipilih memenuhi tujuan yang ditetapkan. Selain itu, evaluasi juga digunakan untuk menentukan apakah diperlukan pengembangan model tambahan atau perbaikan untuk mencapai hasil yang lebih baik. Evaluasi keakuratan model membantu dalam mengidentifikasi kelemahan dan kekuatan model, memberikan wawasan yang diperlukan untuk pengambilan keputusan lanjutan, dan memastikan bahwa model dapat diandalkan untuk tujuan prediksi atau analisis yang diinginkan.

2.6 Deployment

Tahapan deployment dalam CRISP-DM adalah langkah terakhir dalam siklus pengembangan model, yang melibatkan implementasi model ke dalam lingkungan produksi. Proses ini mencakup perencanaan deployment, implementasi model, uji coba, dan validasi. Dokumentasi lengkap dibuat, pengguna diberikan pelatihan, dan model diintegrasikan dengan proses bisnis yang relevan. Pemeliharaan dan pembaruan dilakukan secara berkala, sementara monitoring kinerja memastikan model tetap optimal dan relevan. Hasil dari model disampaikan kepada pengguna untuk mendukung pengambilan keputusan, dan evaluasi terus dilakukan untuk memastikan bahwa model terus memenuhi tujuan dan kebutuhan bisnis.

3. HASIL DAN PEMBAHASAN

3.1 Data Understanding

Pada tahap pemahaman data, proses penelitian dan eksplorasi data fokus utama terletak pada pemahaman mendalam terhadap konteks bisnis dengan tujuan mengidentifikasi, mengumpulkan, dan menganalisis dataset untuk mencapai sasaran yang telah dijelaskan dalam Business Understanding. Pada tahap ini, penekanan khusus diberikan pada identifikasi sumber data, yang dilakukan melalui dataset HR Analytics dari Data World. Dengan pemahaman yang lebih dalam terhadap dataset HR Analytics, diharapkan dapat memperoleh informasi yang dapat mendukung pengembangan model analitis yang efektif dan relevan dalam konteks manajemen sumber daya manusia. Data bersifat berlabel dan memiliki jumlah kolom sebanyak 35 kolom dan jumlah total record sebanyak 1,470 record.

3.2 Preprocessing Data

Fungsi IS NULL digunakan untuk mengecek apakah suatu nilai dalam kolom adalah Null atau tidak. Jika nilai tersebut Null, hasilnya adalah TRUE. Jika tidak, hasilnya adalah FALSE.

Age	False	OverTime	False
Attrition	False	PercentSalaryHike	False
BusinessTravel	False	PerformanceRating	False
DailyRate	False	RelationshipSatisfaction	False
Department	False	StandardHours	False
DistanceFromHome	False	StockOptionLevel	False
Education	False	TotalWorkingYears	False
EducationField	False	TrainingTimesLastYear	False
EmployeeCount	False	WorkLifeBalance	False
EmployeeNumber	False	YearsAtCompany	False
EnvironmentSatisfaction	False	YearsInCurrentRole	False
Gender	False	YearsSinceLastPromotion	False
HourlyRate	False	YearsWithCurrManager	False
JobInvolvement	False		
JobLevel	False		
JobRole	False		
JobSatisfaction	False		
MaritalStatus	False		
MonthlyIncome	False		
MonthlyRate	False		
NumCompaniesWorked	False		
Over18	False		
-	-		

Gambar 2 output nilai null pada dataset

Dalam hasil pada gambar semua nilai adalah False. Ini berarti bahwa tidak ada nilai null dalam setiap kolom DataFrame. Semua kolom dalam data tersebut memiliki nilai yang lengkap (non-null) pada setiap barisnya. Dengan tidak adanya nilai null, data tersebut siap digunakan untuk analisis lebih lanjut.

Education	EmployeeCount	EmployeeNumber	EnvironmentSatisfaction	HourlyRate	JobInvolvement	JobLevel	JobSatisfaction
3	1	1875	2	78	3	1	2
3	1	174	3	77	3	3	4
2	1	733	4	32	3	3	1
3	1	1499	3	46	3	1	3
4	1	1880	2	63	2	2	3

```

]: employee_data["Education"] = employee_data["Education"].replace({1:"Below College",2:"College",3:"Bachelor's Degree",4:"Postgraduate"})
]: employee_data["EnvironmentSatisfaction"] = employee_data["EnvironmentSatisfaction"].replace({1:"Low",2:"Medium",3:"High"})
]: employee_data["JobInvolvement"] = employee_data["JobInvolvement"].replace({1:"Low",2:"Medium",3:"High"})
]: employee_data["JobLevel"] = employee_data["JobLevel"].replace({1:"Entry Level",2:"Junior Level",3:"Mid Level",4:"Senior Level",5:"Executive Level"})
]: employee_data["JobSatisfaction"] = employee_data["JobSatisfaction"].replace({1:"Low",2:"Medium",3:"High"})
]: employee_data["PerformanceRating"] = employee_data["PerformanceRating"].replace({1:"Low",2:"Good",3:"Excellent"})
]: employee_data["RelationshipSatisfaction"] = employee_data["RelationshipSatisfaction"].replace({1:"Low",2:"Medium",3:"High"})
]: employee_data["WorkLifeBalance"] = employee_data["WorkLifeBalance"].replace({1:"Bad",2:"Good",3:"Better"})

```

Gambar 3 mengubah kategori label dalam fitur angka pada dataset

Code tersebut menggunakan metode `replace` dari pandas untuk mengganti nilai pada kolom "Education" dalam DataFrame `employee\_data`. Penggantian dilakukan dengan menggunakan dictionary yang menentukan pemetaan antara nilai awal dan nilai baru. Dalam hal ini, kolom "Education" awalnya mungkin berisi angka-angka 1, 2, 3, 4, dan 5, yang masing-masing mewakili tingkat pendidikan tertentu.


Dictionary yang diberikan dalam metode `replace` menyatakan bahwa:

- 1 akan diganti dengan "Below College"
- 2 akan diganti dengan "College"
- 3 akan diganti dengan "Bachelor"
- 4 akan diganti dengan "Master"
- 5 akan diganti dengan "Doctor"

Sehingga, setelah eksekusi code tersebut, nilai-nilai pada kolom "Education" akan diganti sesuai dengan mapping yang diberikan. Tujuan umumnya adalah untuk membuat data lebih deskriptif dan memudahkan interpretasi, terutama ketika bekerja dengan kategori atau faktor. Hasil setelah dikategorikan maka sebagai berikut :


Education	EducationField	EnvironmentSatisfaction	Gender	JobInvolvement	JobLevel	JobRole	JobSatisfaction	MaritalStat
Master	Medical	Very High	Male	High	Junior Level	Manufacturing Director	High	Marr
Bachelor	Life Sciences	Low	Male	High	Mid Level	Sales Executive	High	Divorc
Bachelor	Life Sciences	High	Female	Low	Mid Level	Human Resources	High	Marr
Bachelor	Medical	Low	Male	High	Entry Level	Research Scientist	Very High	Marr
College	Medical	High	Male	Medium	Mid Level	Healthcare Representative	Low	Marr

Gambar 4 Daftar fitur kategorik




Gambar 5 Visualisasi Data Atrisi Karyawan

Berdasarkan gambar diatas maka Tingkat atrisi karyawan di organisasi ini mencapai 16,12%, sebuah angka yang jauh melampaui tingkat normal yang disarankan oleh para ahli di bidang Sumber Daya Manusia, yakni antara 4% hingga 6%. Menurut standar tersebut, tingkat atrisi yang tinggi seperti ini dapat dianggap sebagai tanda adanya permasalahan yang perlu segera diatasi. Para ahli *HR* menekankan bahwa tingkat atrisi yang berada di luar kisaran normal dapat berdampak negatif pada stabilitas organisasi. Dengan demikian, organisasi perlu mengambil langkah-langkah proaktif untuk mengurangi tingkat atrisi yang berbahaya ini. Tindakan pencegahan dan perbaikan kondisi kerja, peningkatan kepuasan karyawan, serta strategi retensi bakal menjadi kunci dalam memitigasi dampak negatif yang dapat timbul akibat tingkat atrisi yang tinggi ini.



Gambar 6 Visualisasi Data Atrisi Karyawan faktor gender

Dalam organisasi terlihat bahwa jumlah karyawan pria memiliki proporsi yang signifikan lebih tinggi daripada jumlah karyawan wanita, yakni melebihi 20%. Namun, terdapat temuan bahwa tingkat keluar dari organisasi lebih tinggi di kalangan karyawan pria dibandingkan dengan karyawan wanita. Fenomena ini menunjukkan adanya dinamika yang perlu mendapatkan perhatian khusus dari pihak manajemen. Dalam rangka menjaga keseimbangan gender dan meminimalkan tingkat atrisi, organisasi mungkin perlu melakukan analisis lebih lanjut untuk memahami penyebab di balik perbedaan ini dan mengimplementasikan strategi yang bertujuan untuk meningkatkan retensi dan kepuasan karyawan, terutama di kalangan karyawan pria.



Gambar 7 Visualisasi F_score dari uji anova

Analisis Variansi (ANOVA) adalah suatu metode statistik yang digunakan untuk membandingkan rata-rata antara tiga atau lebih kelompok yang independen. Tujuan utama dari ANOVA adalah untuk menilai apakah ada perbedaan signifikan di antara rata-rata kelompok-kelompok tersebut. Analisis hasil dengan memeriksa nilai p-value. Jika nilai p-value cukup rendah (biasanya di bawah tingkat signifikansi yang ditentukan, misalnya 0.05), maka kita dapat menolak hipotesis nol dan menyimpulkan bahwa terdapat perbedaan signifikan antara rata-rata kelompok-kelompok tersebut.

Pembahasan :

1. Nilai F yang Lebih Besar:

- Nilai F adalah statistik uji dalam uji ANOVA. Jika nilai F lebih besar, itu menunjukkan adanya perbedaan yang lebih besar antara rata-rata kelompok-kelompok yang diuji. Dengan kata lain, semakin tinggi nilai F, semakin kuat hubungan antara variabel independen (kelompok) dan variabel dependen (data pengamatan).

2. Nilai p di Bawah Tingkat Signifikansi:

- Nilai p adalah ukuran signifikansi statistik. Jika nilai p kurang dari tingkat signifikansi yang telah ditentukan (biasanya 0,05), kita dapat menolak hipotesis nol. Hipotesis nol dalam konteks uji ANOVA menyatakan bahwa tidak ada perbedaan signifikan antara rata-rata kelompok-kelompok yang diuji.
- Jadi, jika nilai $p < 0,05$, kita dapat menyimpulkan bahwa terdapat perbedaan signifikan antara setidaknya dua kelompok yang diuji.

```
{'Age': {'f_scores': 38.175886789733404, 'p_value': 8.356308021102401e-10},
'DailyRate': {'f_scores': 4.726639837649272, 'p_value': 0.02985816066026101},
'DistanceFromHome': {'f_scores': 8.968276593814723,
'p_value': 0.0027930600802132115},
'HourlyRate': {'f_scores': 0.06879597773678614,
'p_value': 0.7931347689944519},
'MonthlyIncome': {'f_scores': 38.488818983801764,
'p_value': 7.147363985353002e-10},
'MonthlyRate': {'f_scores': 0.3379164577081446,
'p_value': 0.5611235982243229},
'NumCompaniesWorked': {'f_scores': 2.78228670165566,
'p_value': 0.09552526205649159},
'PercentSalaryHike': {'f_scores': 0.266728168623382,
'p_value': 0.6056128238894396},
'StockOptionLevel': {'f_scores': 28.140500912238704,
'p_value': 1.301014966002024e-07},
'TotalWorkingYears': {'f_scores': 44.25249144286461,
'p_value': 4.061878111266676e-11},
'TrainingTimesLastYear': {'f_scores': 5.211646072556778,
'p_value': 0.02257849973719727},
'YearsAtCompany': {'f_scores': 27.00162376300353,
'p_value': 2.3188716103859732e-07},
```

Gambar 8 membandingkan f_score dan p_value dari uji anova.

Berdasarkan hasil analisis ANOVA, berikut adalah fitur-fitur yang menunjukkan hubungan yang kuat dengan atrisi karyawan, seperti yang ditunjukkan oleh nilai F yang tinggi dan nilai p yang sangat rendah:

Table 1 Hasil Uji ANOVA

No	Features	F_score	P_value
1.	Age	38.175886789733404	8.356308021102401e-10
2.	DistanceFromHome	8.968276593814723	0.0027930600802132115
3.	MonthlyIncome	38.488818983801764	7.147363985353002e-10
4.	StockOptionLevel	28.140500912238704	1.301014966002024e-07
5.	TotalWorkingYears	44.25249144286461	4.061878111266676e-11)
6.	YearsAtCompany	27.00162376300353	2.3188716103859732e-07
7.	YearsWithCurrManager	36.71231147388509	1.7369867845240718e-09

Fitur-fitur ini menunjukkan bahwa karyawan yang lebih tua, yang tinggal lebih jauh dari tempat kerja, yang berpenghasilan lebih tinggi, yang memiliki opsi saham, yang memiliki pengalaman kerja lebih lama, yang bekerja di perusahaan lebih lama, yang memiliki peran yang sama lebih lama, dan yang memiliki manajer yang sama lebih lama, cenderung lebih rentan untuk atrisi.


Berdasarkan hasil analisis ANOVA, berikut adalah fitur-fitur yang tidak menunjukkan hubungan yang signifikan dengan atrisi karena nilai p yang sangat tinggi:

1. DailyRate (nilai p: 0.02985816066026101)
2. HourlyRate (nilai p: 0.7931347689944519)
3. NumCompaniesWorked (nilai p: 0.09552526205649159)
4. PercentSalaryHike (nilai p: 0.6056128238894396)
5. TrainingTimesLastYear (nilai p: 0.02257849973719727)
6. YearsSinceLastPromotion (nilai p: 0.2057899591624541)

Fitur-fitur ini menunjukkan bahwa karyawan dengan karakteristik ini tidak lebih rentan untuk atrisi daripada karyawan dengan karakteristik lainnya. Sehingga penting bagi organisasi untuk memperhatikan fitur-fitur signifikan yang teridentifikasi dan mempertimbangkannya ketika menerapkan strategi untuk mengurangi tingkat atrisi.

Uji Chi-Square

Uji Chi-square adalah sebuah metode statistik yang digunakan untuk menguji hubungan antara dua variabel kategorikal dari satu populasi. Metode ini cocok digunakan ketika data yang diamati bersifat kategorikal dan tidak bersifat numerik[18]. Misalnya, dapat digunakan untuk menguji apakah ada hubungan antara jenis kelamin (variabel kategorikal) dan kecenderungan suka atau tidak suka terhadap suatu produk (variabel kategorikal).



Gambar 9 Uji chi-square

Nilai Chi-square dihitung berdasarkan perbedaan antara frekuensi yang diamati dan frekuensi yang diharapkan jika tidak ada hubungan antara variabel tersebut. Hasil uji ini menghasilkan nilai statistik Chi-square dan p-value. P-value yang dihasilkan dari uji Chi-square digunakan untuk membuat keputusan mengenai hipotesis nol (null hypothesis). Hipotesis nol dalam konteks ini biasanya menyatakan bahwa tidak ada hubungan antara dua variabel kategorikal [19]. Jika p-value rendah (biasanya di bawah tingkat signifikansi yang ditentukan sebelumnya, seperti 0.05), maka kita dapat menolak hipotesis nol dan menyimpulkan bahwa terdapat hubungan yang signifikan antara kedua variabel tersebut.

Uji Chi-square memiliki beberapa varian, seperti uji Chi-square Pearson dan uji Chi-square independen. Uji ini sering digunakan dalam berbagai bidang, termasuk ilmu sosial, kedokteran, dan bisnis, untuk mencari hubungan antara variabel kategorikal.

	Features	Chi_2 Statistic	P_value
0	BusinessTravel	24.182414	0.00000560861447644993
1	Department	10.796007	0.00452560657447963286
2	Education	3.073961	0.54552533765659494414
3	EducationField	16.024674	0.00677398013902521211
4	EnvironmentSatisfaction	22.503881	0.00005123468906289433
5	Gender	1.116967	0.29057244902890855265
6	JobInvolvement	28.492021	0.00000286318063671342
7	JobLevel	72.529013	0.00000000000000663468
8	JobRole	86.190254	0.00000000000000275248
9	JobSatisfaction	17.505077	0.00055630045103875563
10	MaritalStatus	46.163677	0.00000000009455511060
11	OverTime	87.564294	0.00000000000000000001
12	PerformanceRating	0.000155	0.99007454659345761616
13	RelationshipSatisfaction	5.241068	0.15497244371052629197
14	WorkLifeBalance	16.325097	0.00097256988453488236

Gambar 10 membandingkan chi-square dan P_value

Membandingkan Chi-square Statistik Dan P_Value Dari Uji Chi-square.

Analisis statistik menunjukkan bahwa sejumlah fitur memiliki hubungan yang signifikan dengan atrisi karyawan, seiring dengan nilai p (p-value) yang sangat kecil, sering kali di bawah tingkat signifikansi yang umumnya dipilih, yaitu 0,05. Nilai p yang lebih kecil menandakan kekuatan bukti yang lebih tinggi untuk menolak hipotesis nol, menunjukkan adanya hubungan yang signifikan. Berikut adalah beberapa fitur yang menonjol:

- **BusinessTravel:** Nilai p yang sangat kecil (0.0000056) memberikan indikasi kuat tentang adanya hubungan yang signifikan antara pola perjalanan bisnis dan atrisi karyawan.
- **Department:** Dengan nilai p sebesar 0.0045, fitur ini juga menunjukkan hubungan yang signifikan dengan atrisi karyawan.
- **JobLevel:** P-value yang sangat kecil (0.000000000000000663) menandakan bahwa tingkat jabatan karyawan berperan signifikan dalam tingkat atrisi.
- **MaritalStatus:** Nilai p yang sangat kecil (0.0000000000946) menunjukkan hubungan yang signifikan antara status pernikahan dan atrisi karyawan.
- **OverTime:** Nilai p yang sangat kecil (0.0000000000000000001) menyoroti hubungan yang signifikan antara lembur dan atrisi.

3.3 Implementasi Algoritma

Setelah menyelesaikan tahap preprocessing, langkah berikutnya adalah memasuki tahap pemodelan karena data telah siap untuk digunakan. Pada tahap pemodelan ini, dilakukan serangkaian pengujian model machine learning pada dataset dengan menerapkan algoritma Regresi Logistik dan Support Vector Machine. Untuk mengevaluasi akurasi model, dataset dibagi menjadi dua bagian, dengan 70% digunakan untuk melatih model (train) dan 30% sisanya untuk menguji model (test).

a. Algoritma Regresi Logistik

Regresi logistik adalah metode statistik yang digunakan untuk menganalisis hubungan antara satu atau lebih variabel independen dengan variabel dependen biner. Variabel dependen biner mengindikasikan dua kategori yang mungkin, seperti "ya" atau "tidak", "sukses" atau "gagal", "1" atau "0". Tujuan dari regresi logistik adalah memodelkan probabilitas bahwa variabel dependen mengambil nilai satu dari fungsi linier kombinasi variabel independen. Dalam regresi logistik, kita menggunakan variabel independen (yang bisa berupa nominal, ordinal, interval, atau rasio) untuk menjelaskan atau memprediksi variabel dependen yang bersifat biner.

Tujuannya adalah untuk memodelkan probabilitas bahwa variabel dependen akan mengambil nilai satu. Ini dilakukan dengan menggabungkan variabel independen dalam fungsi matematika yang menggunakan logika untuk memberikan hasil di antara 0 dan 1.


Adapun hasil dari tahap *modelling* pada fase ini adalah sebagai berikut.

```
=====
CONFUSION MATRIX:
[[351  19]
 [ 41  30]]
ACCURACY SCORE:
0.8639
CLASSIFICATION REPORT:
              0              1  accuracy  macro avg  weighted avg
precision    0.895408    0.612245    0.863946    0.753827    0.849820
recall       0.948649    0.422535    0.863946    0.685592    0.863946
f1-score     0.921260    0.500000    0.863946    0.710630    0.853438
support      370.000000    71.000000    0.863946    441.000000    441.000000
```

Gambar 11 Hasil algoritma regresi logistik

Akurasi adalah ukuran seberapa baik model memprediksi kedua kelas dengan benar. Dihitung sebagai $(TP + TN) / (TP + TN + FP + FN)$. Dalam kasus ini, skor akurasi adalah 0,8639 atau 86,39%.

Berikut hasil dari algoritma *logistic regression* terhadap data aktual dan data prediksi .



Gambar 12 Precision algoritma regresi logistik


Berdasarkan hasil evaluasi kinerja model logistic regression, dapat disimpulkan bahwa model memiliki kinerja yang baik dalam memprediksi kelas 0, sebagaimana ditunjukkan oleh presisi, recall, dan f1-score yang tinggi untuk kelas tersebut. Namun, kinerja model menurun signifikan saat memprediksi kelas 1, dengan presisi, recall, dan f1-score yang lebih rendah. Akurasi keseluruhan model mencapai 86.39%, namun perlu diperhatikan bahwa tingkat akurasi tersebut dapat mengalami bias akibat ketidakseimbangan jumlah instansi antara kelas 0 dan kelas 1. Oleh karena itu, untuk meningkatkan kinerja model, perhatian khusus perlu diberikan pada peningkatan prediksi untuk kelas 1.

b. Algoritma Support vector machine

SVM adalah suatu aturan algoritma *machine learning* berupa *supervised learning* yang digunakan untuk setiap klasifikasi dan tantangan regresi. Dimanfaatkan dalam masalah

klasifikasi, dalam algoritma SVM, mengarah untuk memplot setiap item pengetahuan sebagai batas tertentu dalam ruang n-dimensi (dimana n adalah banyak fitur yang dimiliki) dengan nilai setiap fitur menjadi nilai koordinat tertentu

Hasil dari tahap *modelling* pada fase ini adalah sebagai berikut.




Gambar 13 Hasil Akurasi algoritma SVM

```
=====
CONFUSION MATRIX:
[[347  23]
 [ 44  27]]
ACCURACY SCORE:
0.8481
CLASSIFICATION REPORT:
              0              1  accuracy  macro avg  weighted avg
precision    0.887468    0.540000  0.848073    0.713734    0.831526
recall       0.937838    0.380282  0.848073    0.659060    0.848073
f1-score     0.911958    0.446281  0.848073    0.679119    0.836985
support     370.000000    71.000000  0.848073   441.000000   441.000000
```

Gambar 14 Hasil Akurasi , confusion matrix dan classification report

Hasil dari model yang menggunakan algoritma Support Vector Machine (SVM) dapat dianalisis melalui Confusion Matrix, di mana ditemukan True Positive (TP) sebanyak 347, False Positive (FP) sebanyak 23, False Negative (FN) sebanyak 44, dan True Negative (TN) sebanyak 27. Dengan merinci elemen-elemen ini, kita dapat mengukur performa model secara lebih rinci. Akurasi model, yang menggambarkan tingkat kebenaran keseluruhan, dihitung sebagai jumlah True Positive dan True Negative dibagi dengan total jumlah instansi, menghasilkan nilai akurasi sebesar 84,81%. Nilai akurasi yang tinggi ini menunjukkan bahwa model SVM telah memberikan prediksi dengan tingkat kebenaran yang memadai. Meskipun begitu, perlu juga mempertimbangkan metrik evaluasi lainnya seperti presisi, recall, dan F1-score untuk mendapatkan pemahaman yang lebih holistik terkait kinerja model.


Berikut gambar visualisasi data hasil dari algoritma *Support Vector Machine* terhadap data aktual dan data prediksi .



Gambar 15 Visualisasi data algoritma *support vector machine*

Berdasarkan gambar diatas menghasilkan sebuah scatter plot yang membandingkan nilai aktual (ditampilkan sebagai lingkaran biru) dengan nilai prediksi dari model Support Vector Machine (SVM) (ditampilkan sebagai silang merah). Sumbu x menunjukkan indeks dari setiap sampel, sedangkan sumbu y merepresentasikan label kelas yang sesuai. Setiap titik pada grafik mencerminkan satu sampel dalam set pengujian, memberikan gambaran visual terhadap sejauh mana model SVM sesuai dengan label kelas yang sebenarnya. Model yang efektif akan memiliki silang merah yang mendekati pola lingkaran biru, menunjukkan prediksi yang akurat. Visualisasi ini memberikan pandangan langsung terhadap kualitas prediksi model dengan menyoroti perbedaan antara nilai prediksi dan nilai aktual.

Comparing Model Performance



Gambar 16 Visualisasi perbandingan dari algoritma

Berdasarkan hasil dari kedua model klasifikasi yang telah dievaluasi, dan perbandingan performanya mengungkapkan perbedaan signifikan. Model pertama *Logistic Regression* memiliki akurasi sebesar 86,39% sedangkan model kedua *support vector machine* (SVM) mencapai tingkat akurasi yang sedikit lebih tinggi, yaitu 84.81%. Dalam hal presisi, baik model pertama maupun kedua menunjukkan kecenderungan untuk memiliki presisi yang lebih tinggi untuk kelas negatif (0) dibandingkan dengan kelas positif (1). Namun, model kedua memiliki tingkat presisi yang lebih tinggi secara keseluruhan untuk kedua kelas. Ketika mempertimbangkan recall, model kedua mengungguli model pertama dalam mengidentifikasi instance dari kelas negatif, sementara model pertama memiliki recall yang lebih tinggi untuk kelas positif. Secara umum, model kedua menunjukkan performa yang lebih baik dengan nilai akurasi yang lebih tinggi dan nilai F1-score yang lebih seimbang untuk kedua kelas. Pemilihan model yang paling sesuai harus didasarkan pada konteks aplikasi dan kebutuhan bisnis spesifik, dan evaluasi lebih lanjut mungkin diperlukan untuk memvalidasi hasil ini.

Untuk membandingkan kedua model, evaluasi utama seperti akurasi, presisi, recall, dan f1-score. Berikut table perbandingan performa antara dua model yang telah dijelaskan sebelumnya:

Tabel 2 Tabel dari hasil perbandingan model

No	Nama	Model Logistic Regression	Model Support vector machine (SVM)
1	Akurasi	86,39%	84,81%
2	Precision untuk kelas 0	89,5%	88.7%
3	Precision untuk kelas 1	61,2%	54 %
4	Recall untuk kelas 0	94,8%	93,7%
5	Recall untuk kelas 1	42,2%	38 %
6	F1-score untuk kelas 0	0: 92.1%	91.1%
7	F1-score untuk kelas 1	50 %	44.6%

4. KESIMPULAN

Penelitian ini memprediksi tingkat atrisi karyawan menggunakan machine learning. Hasil evaluasi dua model klasifikasi, yaitu regresi logistik dan Support Vector Machine (SVM), menunjukkan perbedaan signifikan dalam performa keduanya. Berdasarkan hasil evaluasi kedua model klasifikasi, dapat disimpulkan bahwa model Logistic Regression dan Support Vector Machine (SVM) menunjukkan perbedaan performa yang signifikan. Model Logistic Regression memiliki akurasi lebih tinggi, yaitu sebesar 86,39%, sementara model SVM mencapai akurasi sebesar 84,81%. Kedua model menunjukkan kecenderungan presisi yang lebih tinggi untuk kelas negatif (0) dibandingkan dengan kelas positif (1), namun model SVM memiliki tingkat presisi yang lebih tinggi secara keseluruhan untuk kedua kelas. Dalam hal recall, model SVM unggul dalam mengidentifikasi instance dari kelas negatif, sedangkan model Logistic Regression memiliki recall yang lebih tinggi untuk kelas positif.

Secara keseluruhan, model SVM menunjukkan performa yang lebih baik dengan nilai akurasi yang lebih tinggi dan nilai F1-score yang lebih seimbang untuk kedua kelas. Namun, pemilihan model yang paling sesuai harus didasarkan pada konteks aplikasi dan kebutuhan bisnis spesifik. Evaluasi lebih lanjut mungkin diperlukan untuk memvalidasi hasil ini dan memastikan bahwa model yang dipilih memenuhi tujuan dan kebutuhan penggunaannya.

UCAPAN TERIMA KASIH

Penulis ingin menyampaikan rasa terimakasih kepada seluruh anggota akademis di Universitas Logistik dan Bisnis Internasional, terutama dalam lingkup program studi D4 Teknik Informatika, Terutama kepada Bapak Roni Andarsyah selaku pembimbing penelitian dan atas bimbingan yang sangat berharga selama proses penelitian ini. Ucapan terima kasih juga disampaikan kepada rekan-rekan seangkatan dari D4 Teknik Informatika kelas B Angkatan 2020 atas dukungan yang luar biasa. Tak lupa, rasa terima kasih saya kepada kedua orang tua yang luar biasa, atas dukungan mereka baik secara materiil maupun non-materiil, yang telah menjadi pilar utama dalam perjalanan penelitian ini. Semua kontribusi dan support ini sangat berarti bagi kelancaran dan keberhasilan penelitian ini. Terima kasih banyak.

DAFTAR RUJUKAN

- Alsheref, F. K., Fattoh, I. E., & Mead, W. (2022). Automated Prediction of Employee Attrition Using Ensemble Model Based on Machine Learning Algorithms. *Computational Intelligence and Neuroscience*, 2022. <https://doi.org/10.1155/2022/7728668>
- And, I., & Expert, D. (2022). *Sistem Prediksi Awal Terhadap Atrisi Karyawan Menggunakan Algoritma C4.5 INFORMASI ARTIKEL A B S T R A K* (Vol. 4, Issue 1). <https://ejournal.unper.ac.id/index.php/informatics>
- Biswas, A. K., Seethalakshmi, R., Mariappan, P., & Bhattacharjee, D. (2023). An ensemble learning model for predicting the intention to quit among employees using classification algorithms. *Decision Analytics Journal*, 9. <https://doi.org/10.1016/j.dajour.2023.100335>
- Fadillah, A. P. (2015). Penerapan Metode CRISP-DM untuk Prediksi Kelulusan Studi Mahasiswa Menempuh Mata Kuliah (Studi Kasus Universitas XYZ). In *Jurnal Teknik Informatika dan Sistem Informasi* (Vol. 1).
- Octaviani, P. A., Wilandari, Y., & Ispriyanti, D. (2014). *PENERAPAN METODE KLASIFIKASI SUPPORT VECTOR MACHINE (SVM) PADA DATA AKREDITASI SEKOLAH DASAR (SD) DI KABUPATEN MAGELANG*. 3(4), 811–820. <http://ejournal-s1.undip.ac.id/index.php/gaussian>

- Purnama, I., Saputra, R., & Wibowo, A. (n.d.). *IMPLEMENTASI DATA MINING MENGGUNAKAN CRISP-DM PADA SISTEM INFORMASI EKSEKUTIF DINAS KELAUTAN DAN PERIKANAN PROVINSI JAWA TENGAH*.
- Qutub, A., Al-Mehmadi, A., Al-Hssan, M., Aljohani, R., & Alghamdi, H. S. (2021). Prediction of Employee Attrition Using Machine Learning and Ensemble Methods. *International Journal of Machine Learning and Computing*, 11(2), 110–114. <https://doi.org/10.18178/ijmlc.2021.11.2.1022>
- Raza, A., Munir, K., Almutairi, M., Younas, F., & Fareed, M. M. S. (2022). Predicting Employee Attrition Using Machine Learning Approaches. *Applied Sciences (Switzerland)*, 12(13). <https://doi.org/10.3390/app12136424>
- Santoso, P., Abijono, H., & Anggreini, N. L. (2021). ALGORITMA SUPERVISED LEARNING DAN UNSUPERVISED LEARNING DALAM PENGOLAHAN DATA. *Unira Malang* /, 4(2).
- Setia Arindi, A., Mirza, A., Darma Palembang Jl Jenderal Ahmad Yani No, B., Seberang Ulu, K. I., Palembang, K., & Selatan, S. (2023). *MODEL KLASIFIKASI KINERJA PEGAWAI DENGAN PENERAPAN MACHINE LEARNING MENGGUNAKAN TOOLS PYTHON*. 8(1).
- Setiawan, I., Suprihanto, S., Nugraha, A. C., & Hutahaean, J. (2020). HR analytics: Employee attrition analysis using logistic regression. *IOP Conference Series: Materials Science and Engineering*, 830(3). <https://doi.org/10.1088/1757-899X/830/3/032001>
- Stamolampros, P., Korfiatis, N., Chalvatzis, K., & Buhalis, D. (2019). Job satisfaction and employee turnover determinants in high contact services: Insights from Employees'Online reviews. *Tourism Management*, 75, 130–147. <https://doi.org/10.1016/j.tourman.2019.04.030>
- Suindari, N. M., & Juniariani, N. M. R. (2020). PENGELOLAAN KEUANGAN, KOMPETENSI SUMBER DAYA MANUSIA DAN STRATEGI PEMASARAN DALAM MENGUKUR KINERJA USAHA MIKRO KECIL MENENGAH (UMKM). *KRISNA: Kumpulan Riset Akuntansi*, 11(2), 148–154. <https://doi.org/10.22225/kr.11.2.1423.148-154>
- Umami, A. (n.d.). *Klasifikasi Faktor-faktor yang Mempengaruhi Pengurangan Karyawan Pada Perusahaan "XYZ."*
- Wardhani, F. H., & Lhaksmana, K. M. (2022). Predicting Employee Attrition Using Logistic Regression With Feature Selection. *Sinkron*, 7(4), 2214–2222. <https://doi.org/10.33395/sinkron.v7i4.11783>
- Wurijanto, T., Setiawan, H. B., & Tjandrarini, A. B. (2022). Penerapan Model CRISP-DM pada Prediksi Nasabah Kredit yang Berisiko Menggunakan Algoritma Support Vector Machine.

Tuliskan judul artikel sebagai header halaman ganjil

Jurnal Ilmiah Scroll: Jendela Teknologi Informasi, 10(1).
<https://univ45sby.ac.id/ejournal/index.php/informatika>